

Informe de Análisis: Clasificación de Calidad de Vino Tinto

Proyecto de Machine Learning con modelos de clasificación supervisada

1. Propósito del proyecto

El objetivo del proyecto es construir un flujo de análisis y modelamiento para clasificar vinos tintos según su calidad. Para ello, la variable original quality se transforma en una etiqueta binaria: vinos de baja/regular calidad y vinos de alta calidad. El propósito final es comparar diferentes modelos de clasificación y determinar cuál presenta mejor desempeño predictivo.

2. Dataset y variables utilizadas

El análisis utiliza el dataset Wine Quality - Red Wine, cargado desde el repositorio público de UCI. Este conjunto de datos contiene variables físico-químicas del vino, tales como acidez fija, acidez volátil, ácido cítrico, azúcar residual, cloruros, dióxido de azufre, densidad, pH, sulfatos, alcohol y calidad.

Tipo de variable	Descripción
Variables predictoras	Características físico-químicas del vino
Variable original	quality
Variable objetivo creada	quality_label
Clase 0	Vino de baja o regular calidad
Clase 1	Vino de alta calidad

3. Técnicas aplicadas

- Análisis exploratorio de datos para revisar dimensiones, estructura y distribución de clases.
- Tratamiento de outliers en total sulfur dioxide mediante capping por IQR.
- Conversión de la variable quality en clasificación binaria.
- Separación del dataset en entrenamiento y prueba con train_test_split y estratificación.
- Escalado de características mediante StandardScaler.
- Entrenamiento de modelos supervisados de clasificación.
- Optimización de hiperparámetros con GridSearchCV y validación cruzada.
- Evaluación con accuracy, precision, recall, F1-score, matriz de confusión y curva ROC.

4. Modelos evaluados

Modelo	Motivo de uso
Regresión Logística	Modelo base interpretable para clasificación binaria.
KNN	Modelo basado en cercanía entre observaciones, sensible al escalado.
Random Forest	Modelo robusto, capaz de capturar relaciones no lineales.

5. Métricas de evaluación

El código evalúa los modelos mediante métricas de clasificación. F1-score se utiliza como métrica de optimización en GridSearchCV, ya que permite equilibrar precision y recall. Además, se generan matrices de confusión y curva ROC para analizar visualmente el comportamiento del modelo.

Métrica	Interpretación
---------	----------------

Accuracy	Proporción total de predicciones correctas.
Precision	Qué tan confiables son las predicciones positivas.
Recall	Capacidad del modelo para detectar vinos de alta calidad.
F1-score	Balance entre precision y recall.
AUC	Capacidad general del modelo para separar clases.

6. Hallazgos principales

- La clasificación binaria permite simplificar el problema y enfocarlo en distinguir vinos de alta calidad frente a vinos de menor calidad.
- El tratamiento de outliers reduce el efecto de valores extremos en variables químicas que podrían sesgar el entrenamiento.
- El escalado de variables es una etapa necesaria para modelos sensibles a la escala, principalmente KNN y Regresión Logística.
- La comparación de tres modelos permite establecer una línea base y evaluar alternativas más complejas.
- Random Forest se considera el modelo más prometedor dentro del flujo propuesto, ya que suele capturar relaciones no lineales entre las variables químicas.

7. Conclusiones

- El proyecto implementa un flujo completo de Machine Learning: carga de datos, limpieza, transformación, entrenamiento, optimización y evaluación.
- La variable quality fue transformada correctamente en una etiqueta binaria apta para modelos de clasificación.
- La selección de F1-score como métrica de optimización es adecuada cuando se busca balancear la identificación de vinos de alta calidad y la precisión de las predicciones.
- El modelo Random Forest es una buena alternativa para el problema por su robustez y capacidad de capturar patrones complejos.
- Como mejora futura, se recomienda incorporar análisis de importancia de variables y guardar el mejor modelo entrenado para uso posterior.

8. Cómo ejecutar el código

1. Clonar el repositorio de GitHub.
2. Crear y activar un entorno virtual de Python.
3. Instalar dependencias: numpy, pandas, matplotlib, seaborn y scikit-learn.
4. Ejecutar el script principal o notebook.
5. Revisar la tabla comparativa, matrices de confusión y curva ROC generadas.

Nota: El informe resume el flujo y los hallazgos del código entregado. Las métricas numéricas exactas se generan al ejecutar el script en el entorno local o notebook.